

酒店排序模型的演进之路

苏 帅



同程艺龙

About Me



航空产品研发



同程艺龙

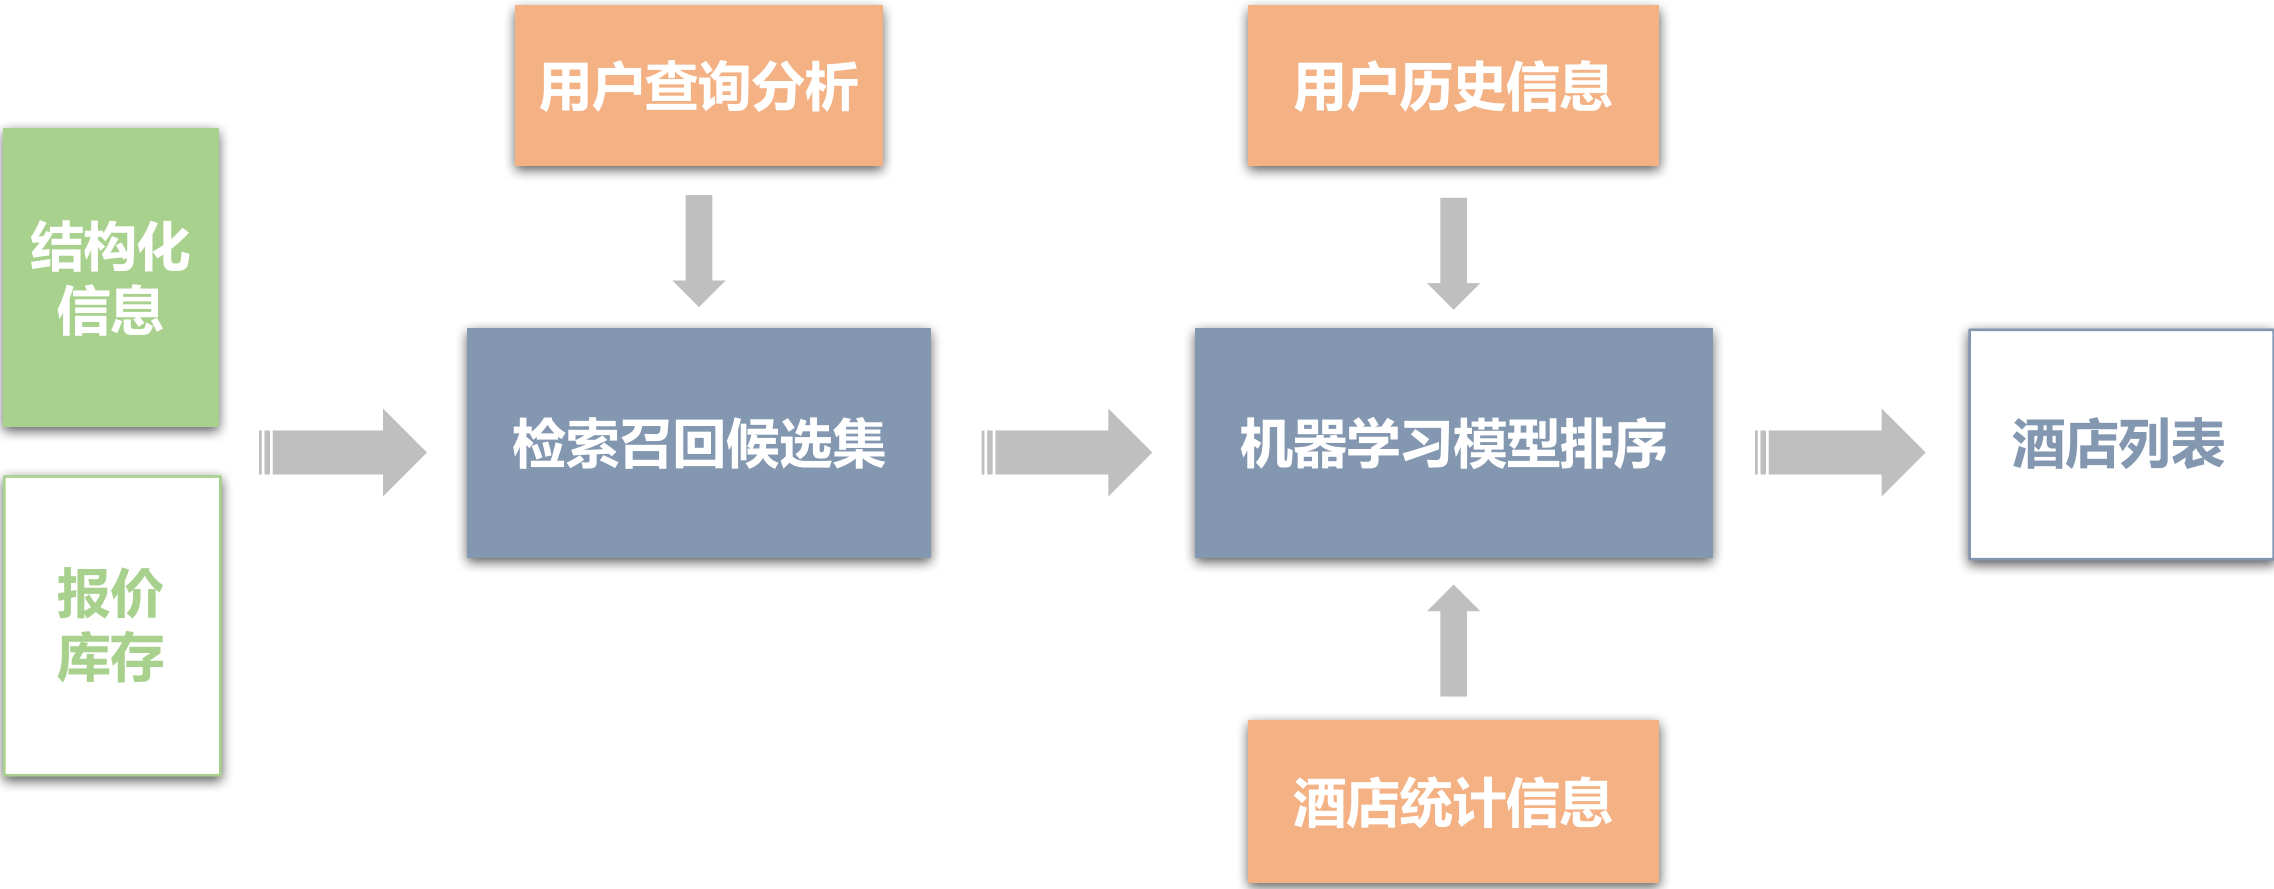
数据分析与挖掘
机器学习算法研发

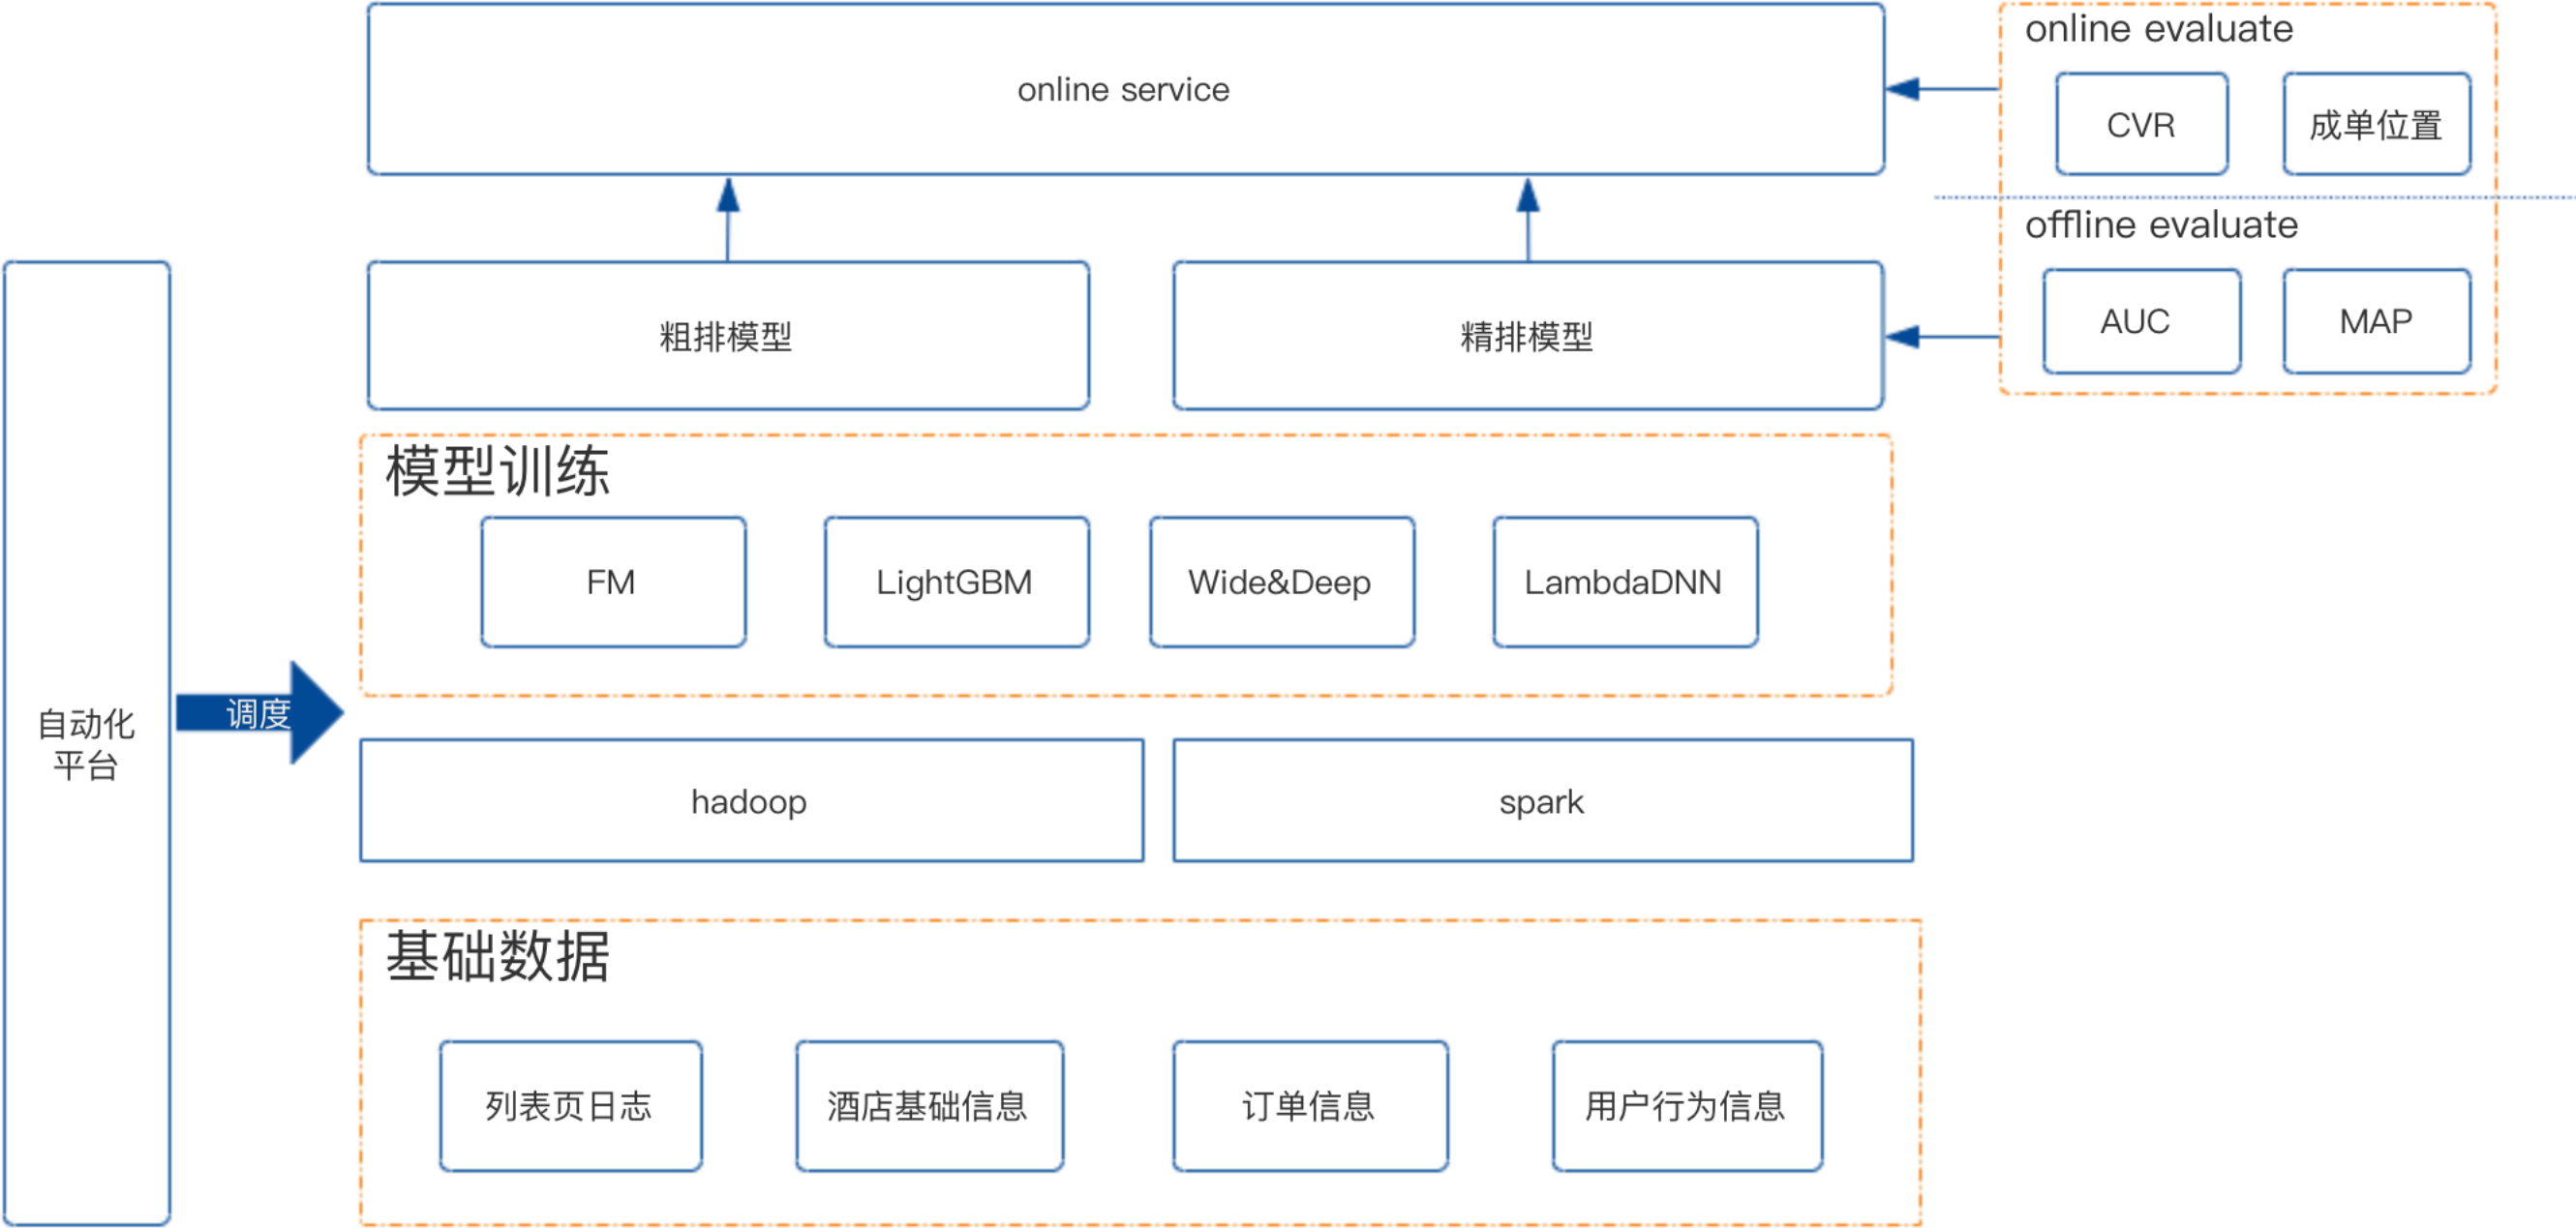
目录



contents

- 1 酒店排序系统的整体架构
- 2 推荐/排序模型的发展现状
- 3 酒店排序模型的技术演进过程
- 4 酒店排序模型的未来发展方向

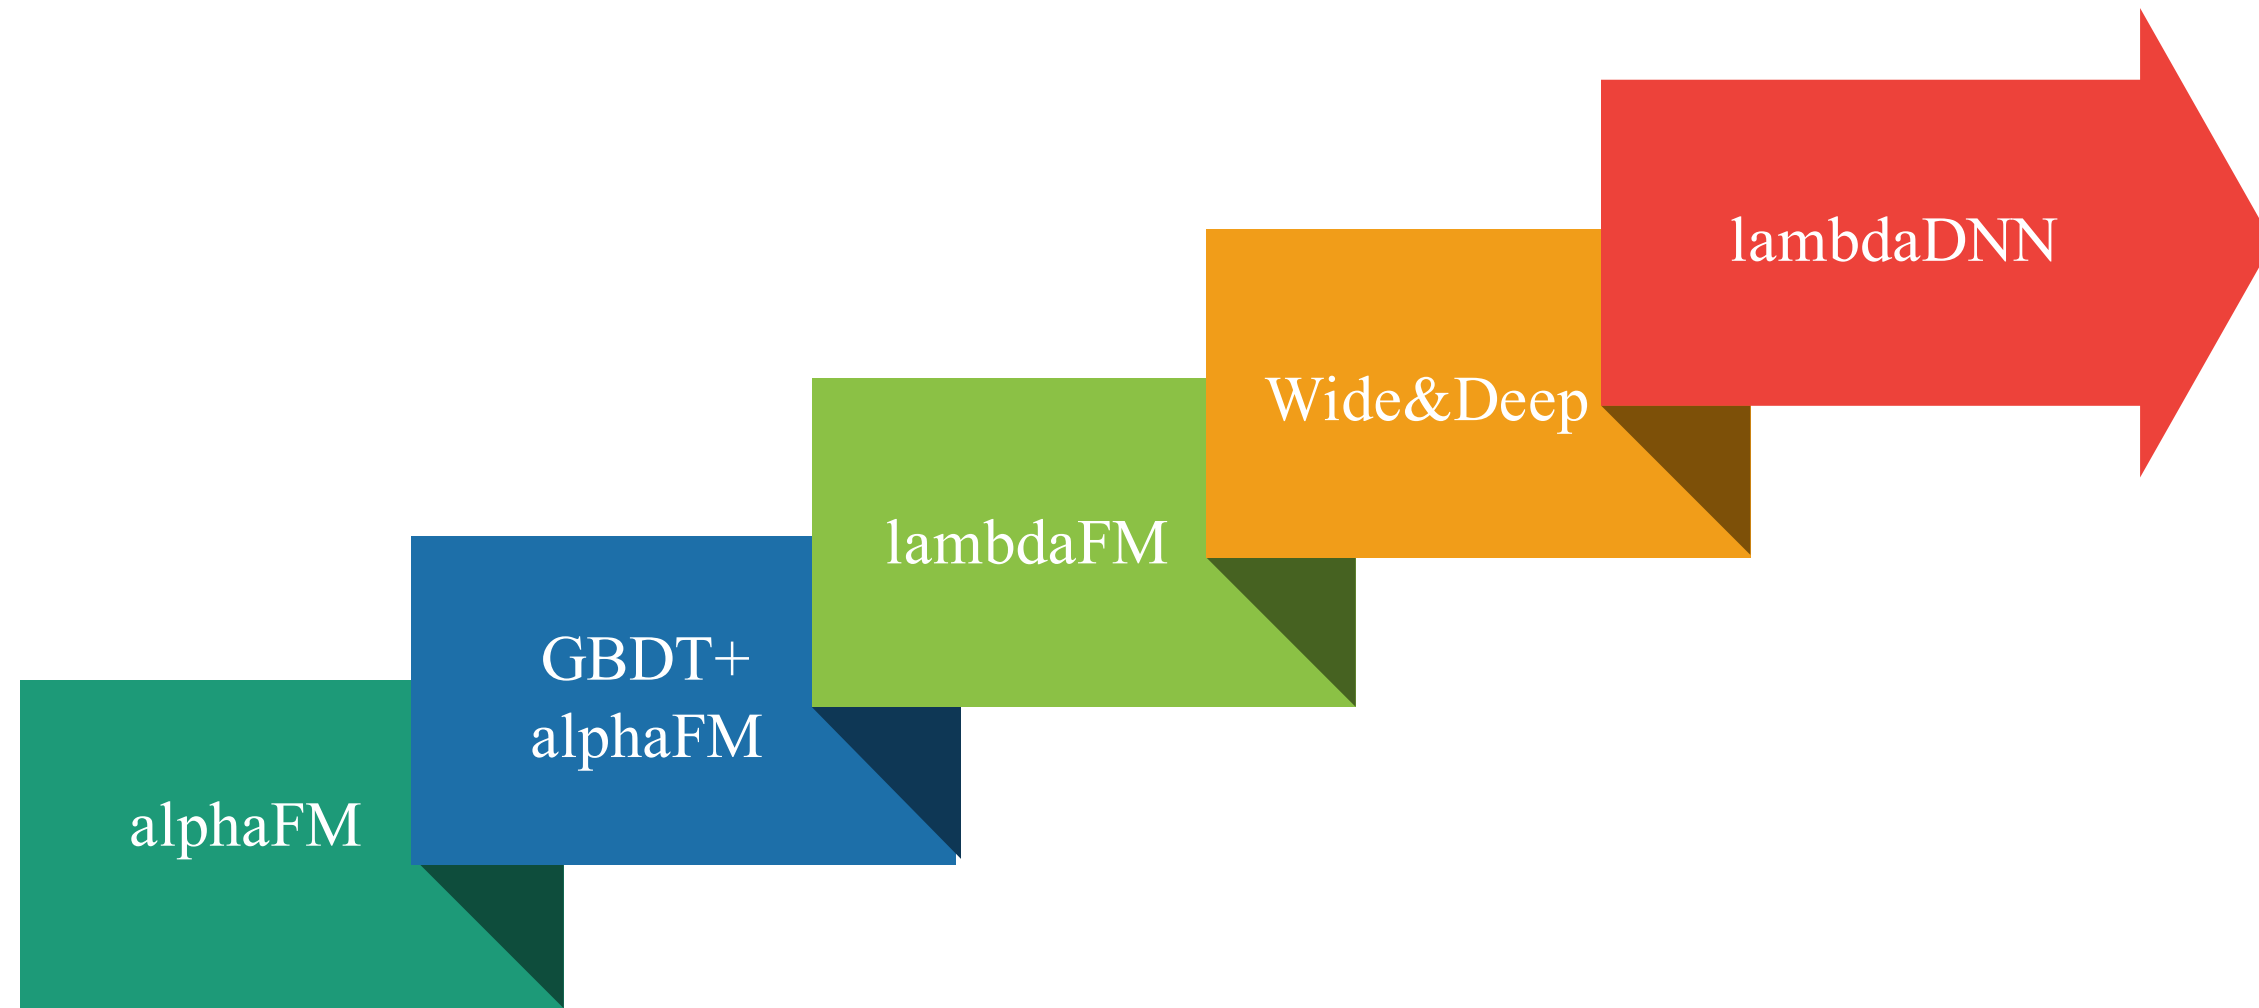








典型技术架构：算法约束下的最优逼近



- ✓ 酒店的维度极其巨大，one-hot后矩阵极其稀疏
- ✓ 需要利用大量统计信息，计算开销量大
- ✓ 模型时效性要求高:毫秒级响应
- ✓ 训练数据呈Power-Law分布，需要大量数据使稀疏部分变得显著

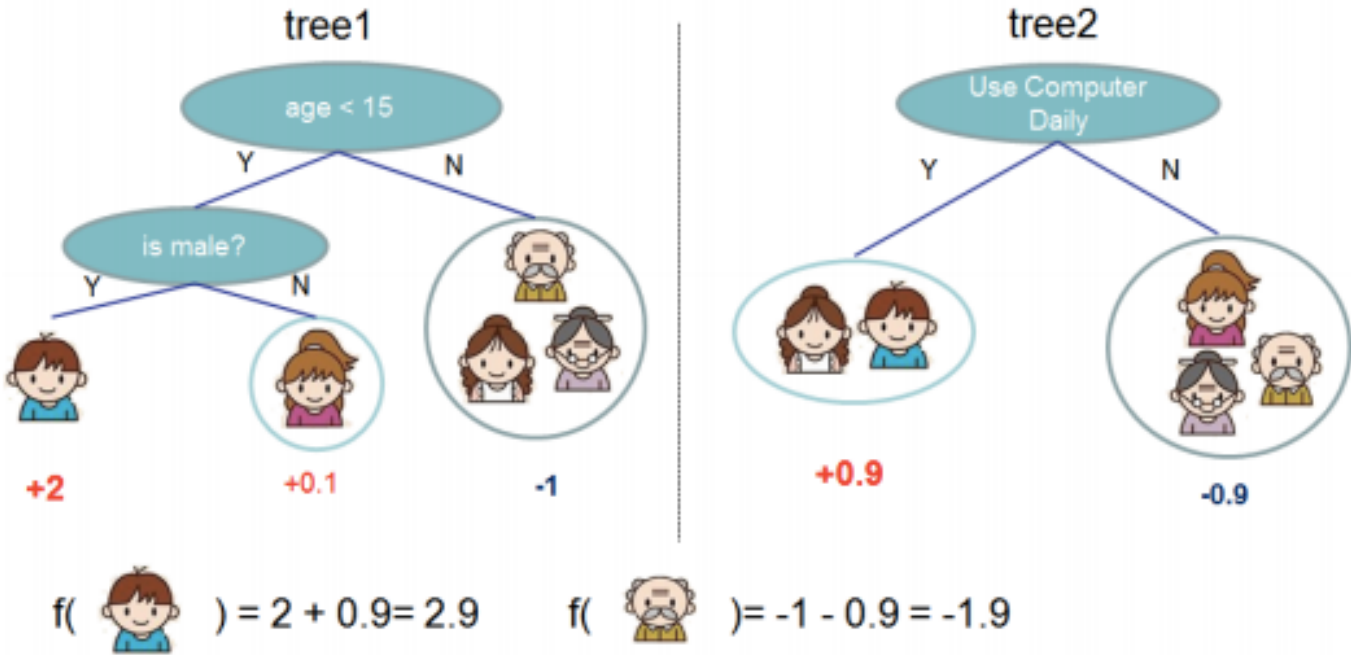
模型和架构co-design

FM(Factorization Machine)

$$w_0 \in \mathbb{R}, x, w \in \mathbb{R}^p, v_i \in \mathbb{R}^k$$
$$\hat{y}^{FM}(x) := w_0 + \sum_{i=1}^p w_i x_i + \sum_{i=1}^p \sum_{j>i}^p \langle v_i, v_j \rangle x_i x_j$$

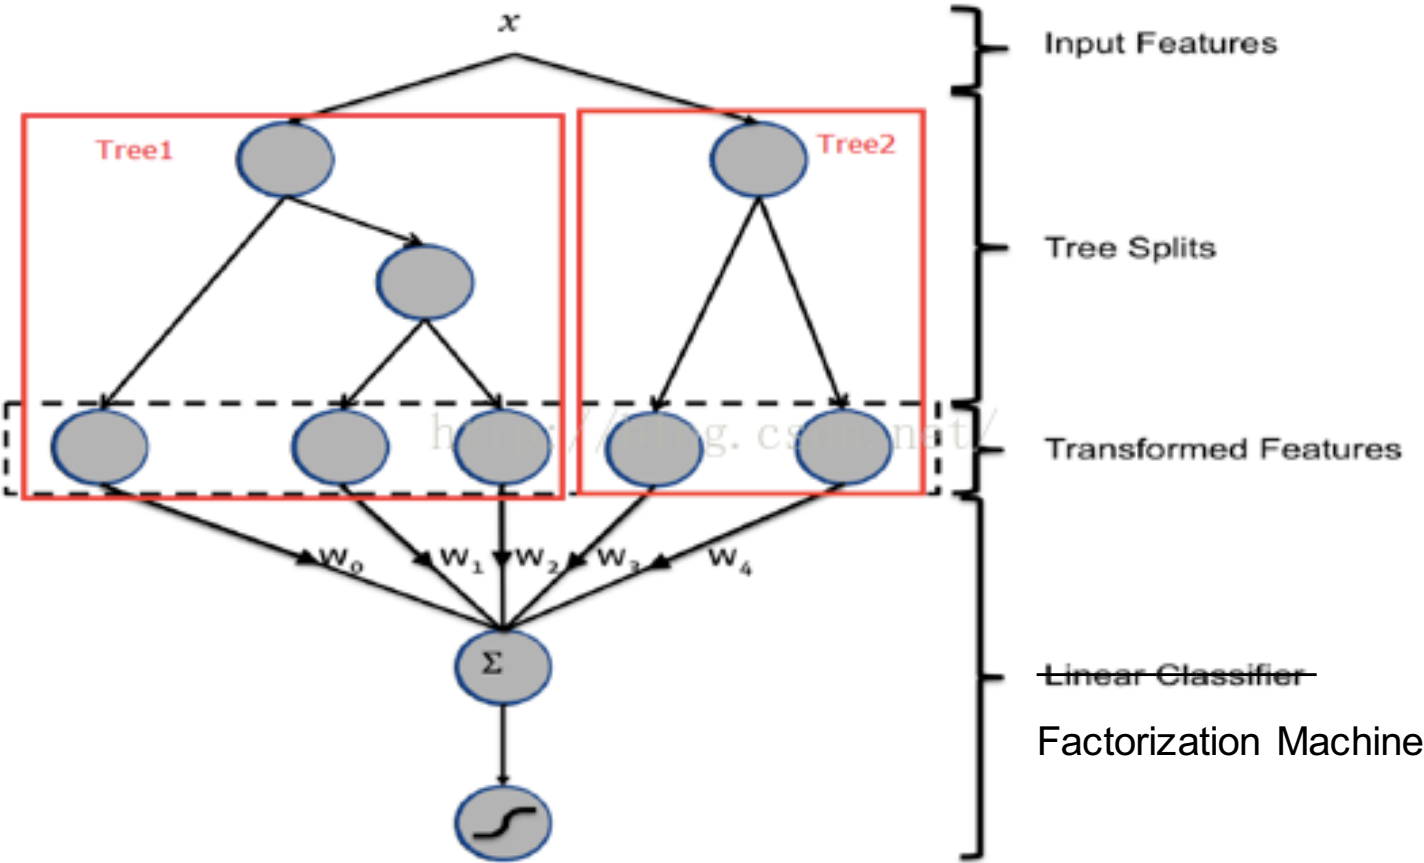
优点：模型结构简单，训练代价低，线上响应快
缺点：依赖特征的挖掘，非线性程度低

GBDT(Gradient Boosting Decision Tree)



优点：具有非线性，抑制过拟合
缺点：无法使用高维稀疏特征


模型组合：



评价指标

AUC

The AUC value is equivalent to the probability that a randomly chosen positive example is ranked higher than a randomly chosen negative example.



Mean average precision(MAP) :

$$MAP = \frac{\sum_{q=1}^Q AveP(q)}{Q}$$

$$AveP = \frac{1}{R} \times \sum_{r=1}^R \frac{r}{position(r)}$$

问题：

离线评估效果较好：

alphafm auc:0.849 map:0.612

alphafm+gbm auc:0.859 map:0.624

线上效果不明显

思考：

AUC：通过概率刻画排名

MAP：直接对排名进行评价

修改目标函数(直接对排名建模)：

logloss—>lambdarank

$$\lambda_{ij} = \frac{-\sigma}{1 + e^{\sigma(s_i - s_j)}} |\Delta Z_{ij}|$$


离线评估


| | | |
|--------------|-----------|-----------|
| fm | auc:0.849 | map:0.612 |
| fm+lightgbm | auc:0.859 | map:0.624 |
| lambdafm | auc:0.768 | map:0.628 |
| lambdafm+gbm | auc:0.796 | map:0.637 |


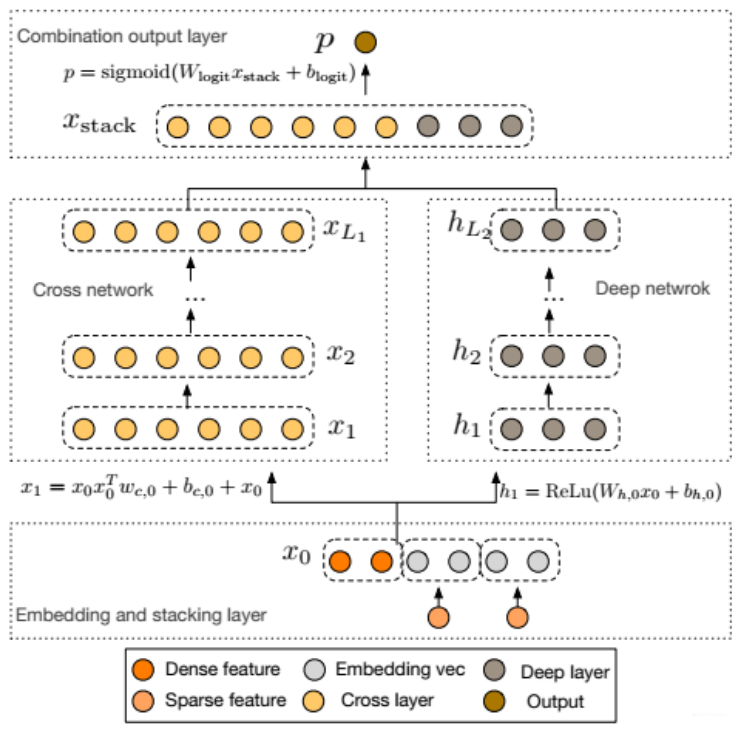

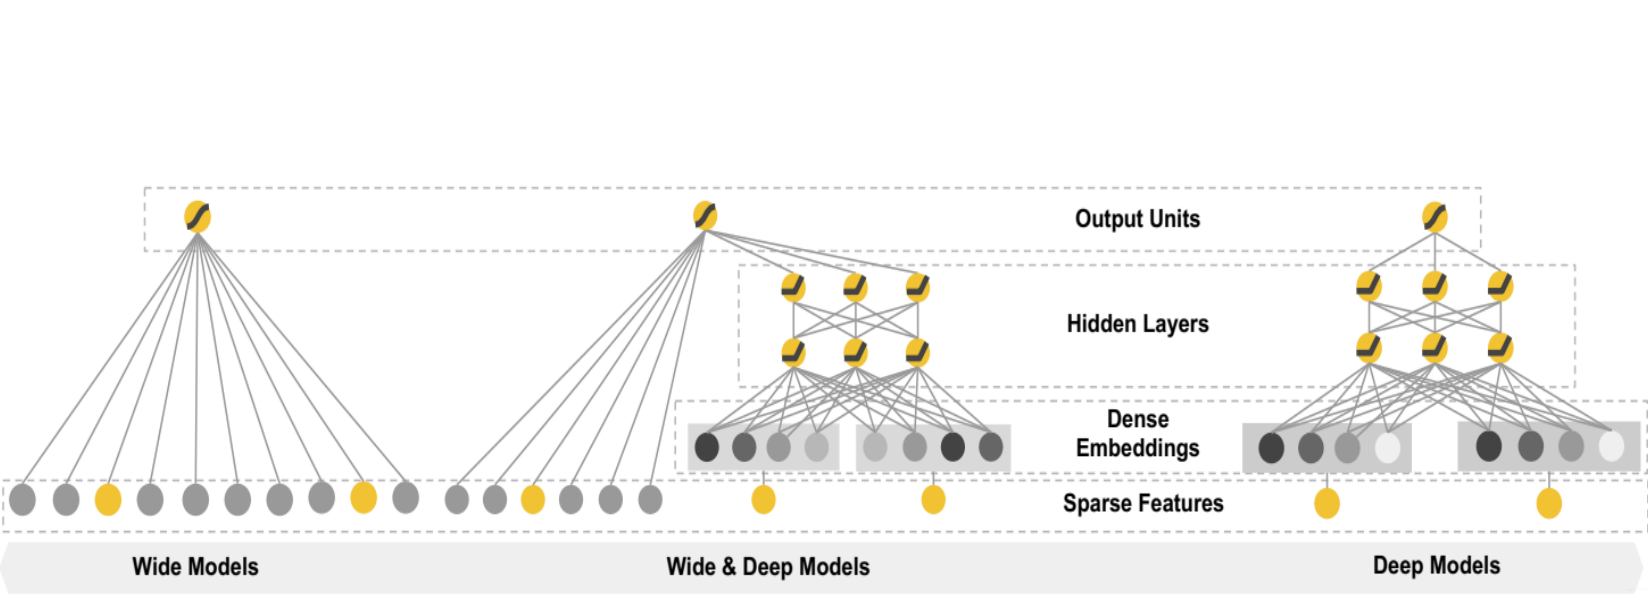
线上评估

| | |
|------|---------|
| CVR | 提升2.49% |
| 成单位置 | 提前7.06% |

UV转化率







选取原则：

◆ 线上系统，充分考虑工程化的问题：

tensorflow serving or 现有平台？

开发周期能否接受？


模型复杂度现有算力是否支持？

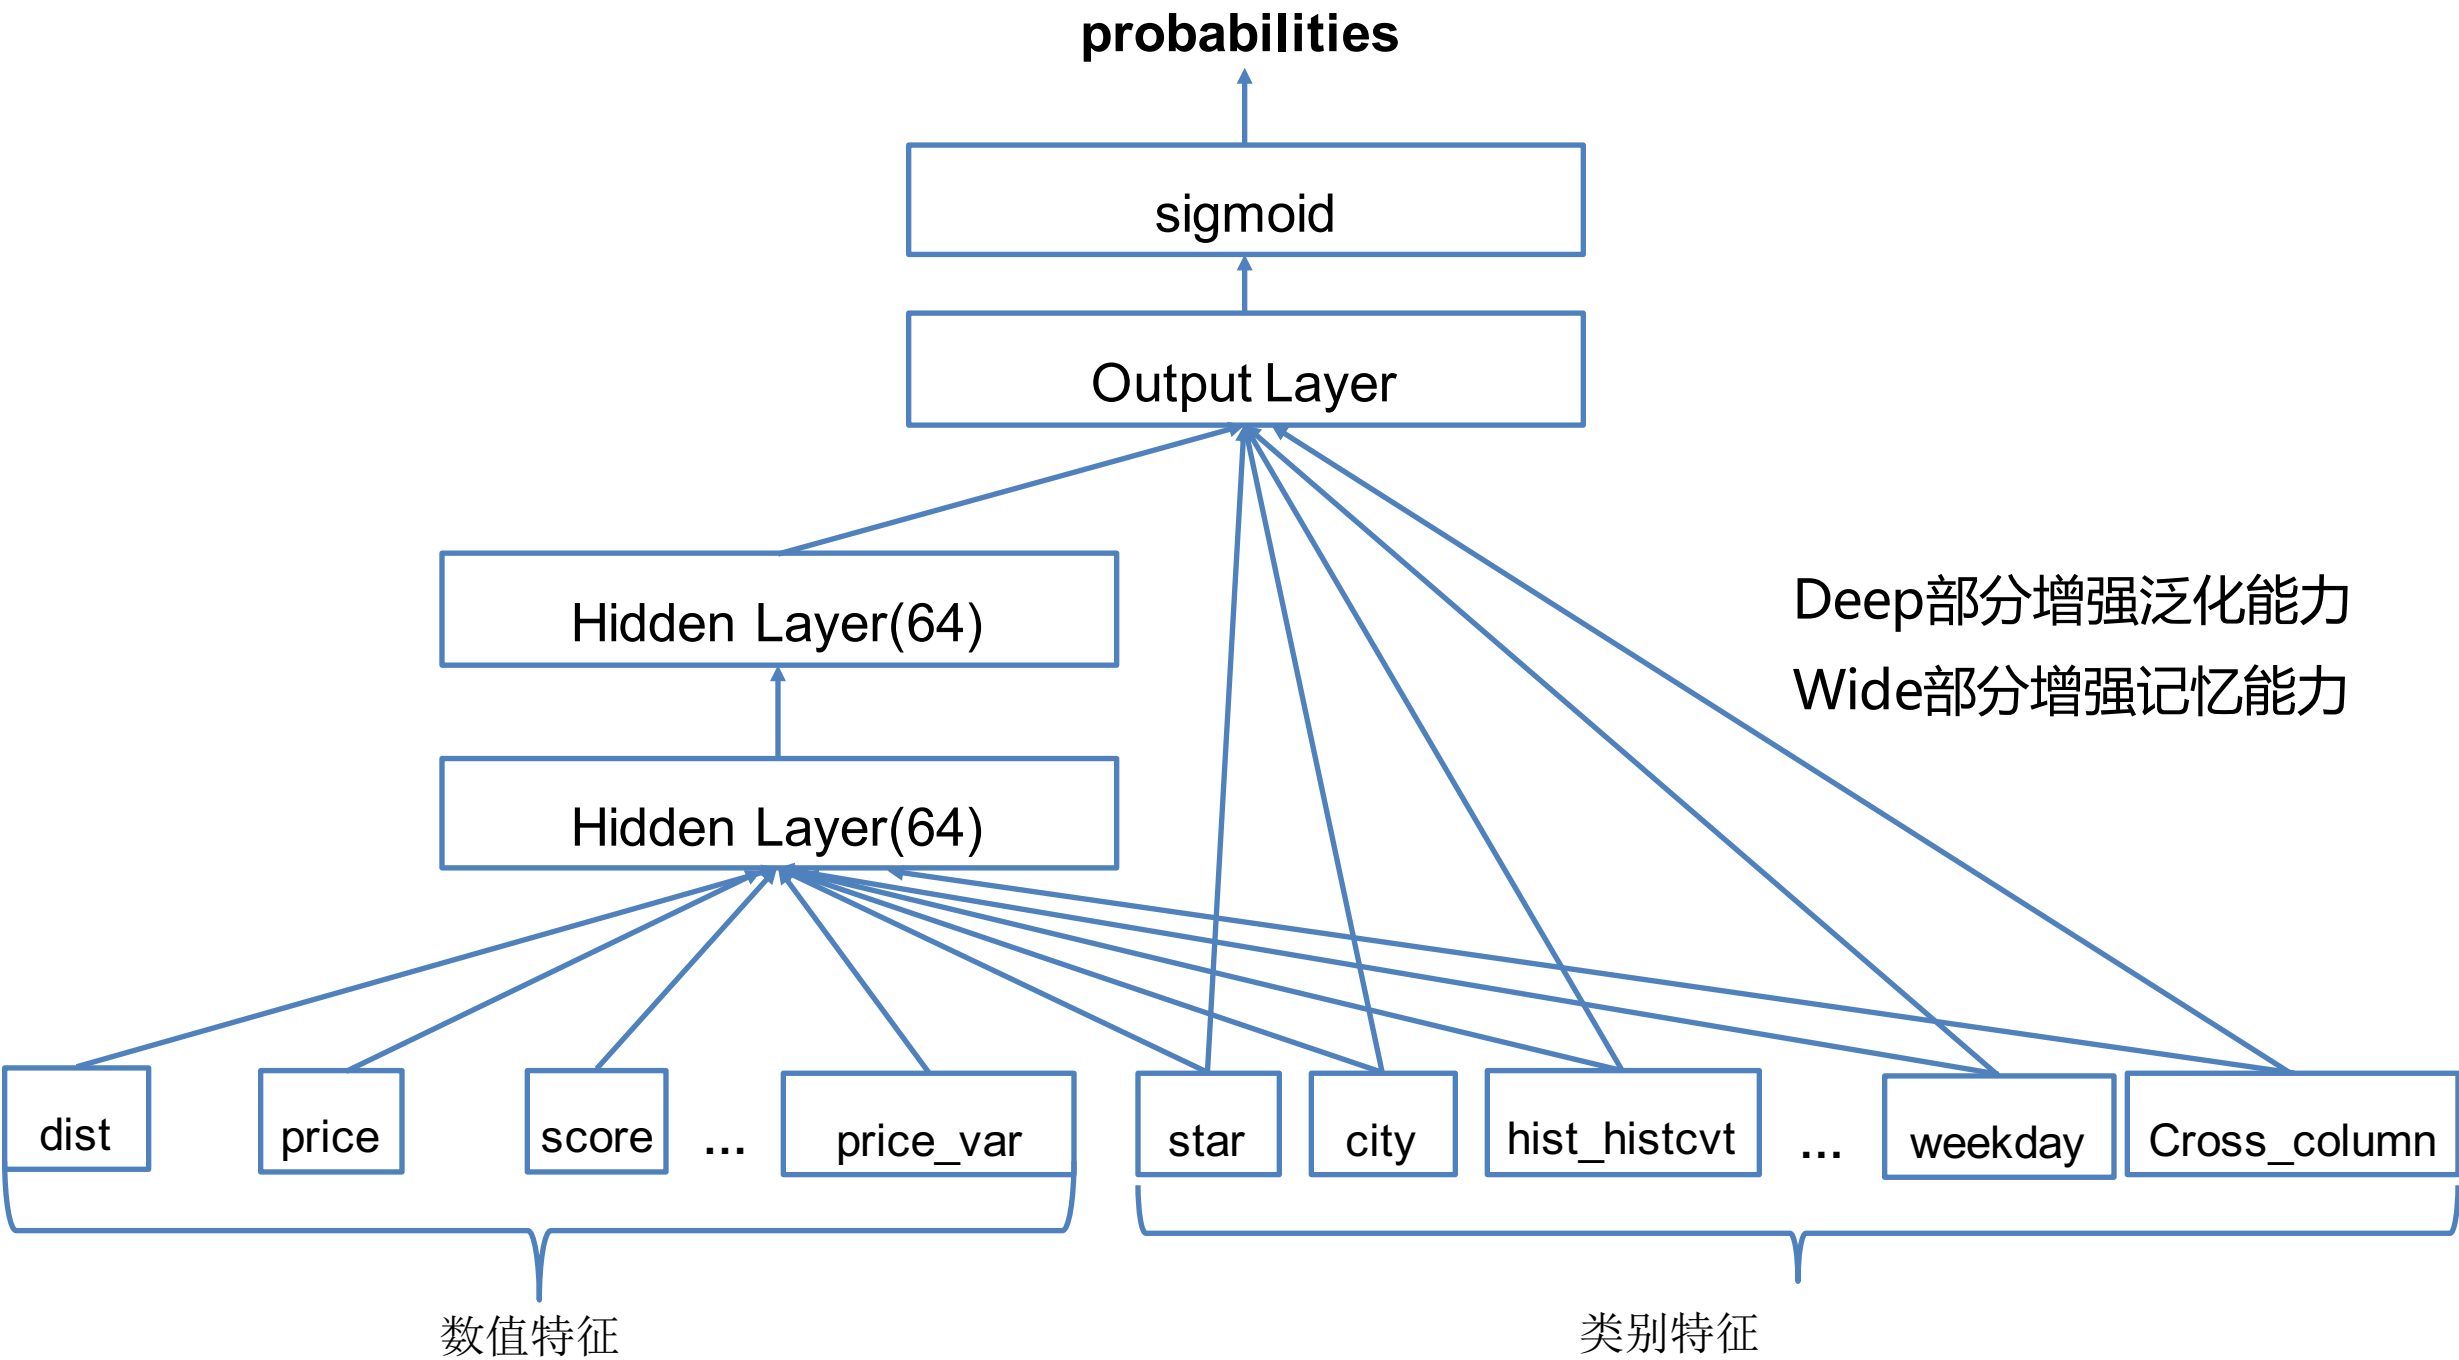
毫秒级响应是否可以达到？

◆ 复用以前模型的成功经验：

针对原模型结构构造了大量经过实践证明有效的特征，是否需要推倒重来？

平稳快速的进行模型演进，避免开发周期长，效果不明显的问题





| 模型 | AUC | MAP |
|------------------------|--------|--------|
| alphafm | 0.8318 | 0.668 |
| lambdafm | 0.7+ | 0.6854 |
| Wide&deep(无分段和交叉特征) | 0.841 | 0.679 |
| Wide&deep(分段特征和少量交叉特征) | 0.8533 | 0.6906 |

线上评估:点击位置提升约3% , 转化率有波动

Wide&Deep vs lambdabfm 转化率提升不明显 Why ?

Wide&Deep

CVR模型, Pointwise

输入：单个酒店的特征 输出：单个酒店的概率值

没有考虑酒店和酒店之间并不是独立同分布的，酒店之间存在相互影响！

lambdabfm

Ranking模型, Pairwise

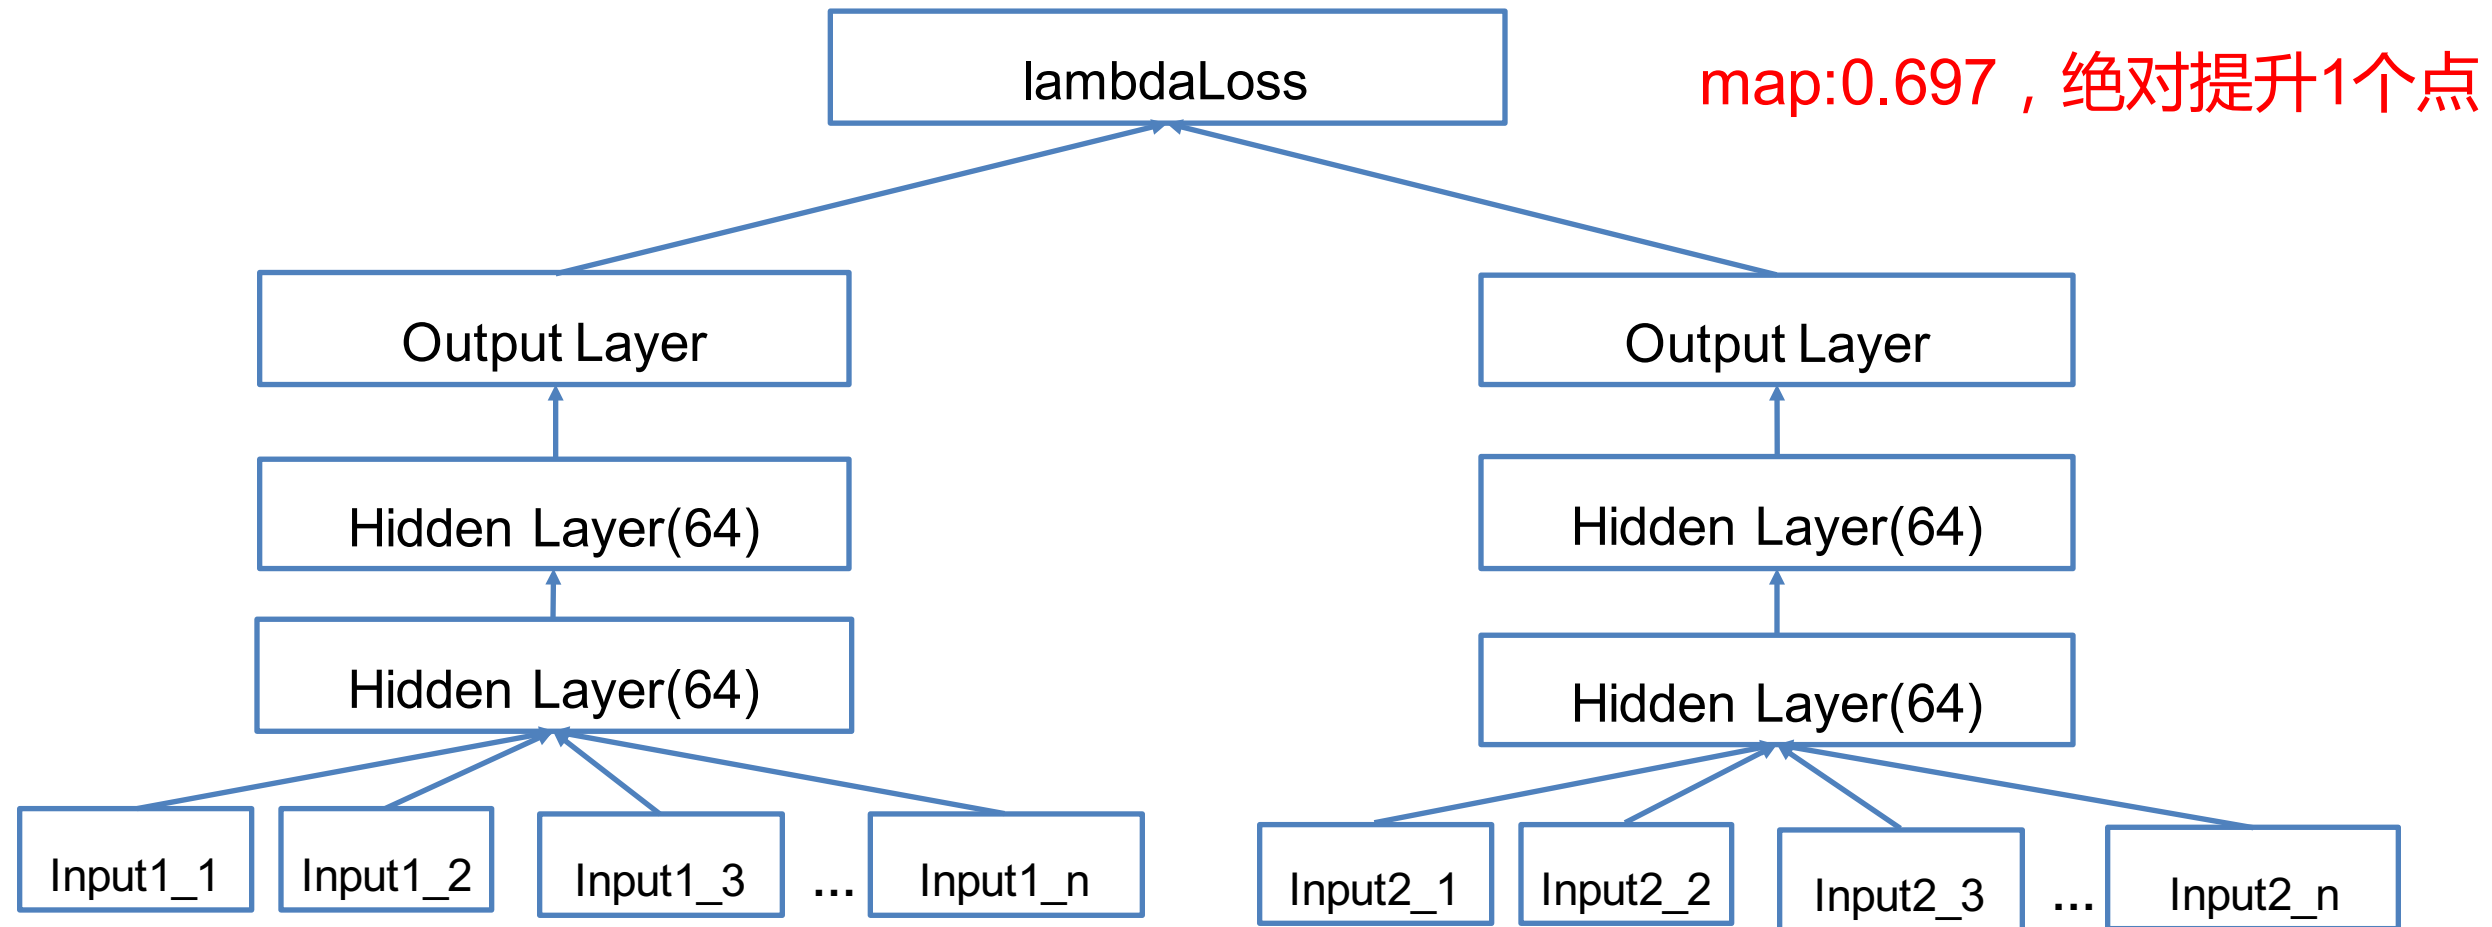
输入：同一个query下的2个酒店的特征，输出：pairwise相对相关度

考虑了酒店之间的相互作用，更符合用户挑选酒店的习惯


Ctr预估模型演进： FM——>Wide&Deep

Ranking模型演进： lambdaFM——>lambdaDNN


LambdaDNN模型结构：



用户有效转换率



平均成单位置



- E&E (explore&exploit)

Exploit : 基于已知最好策略，开发利用已知具有较高回报的item（贪婪、短期回报），对于推荐来讲就是用户已经发现的兴趣，继续加以利用推荐。

Explore : 挖掘未知的潜在可能高回报的的item（非贪婪、长期回报），对于推荐来讲，就是探索用户新的未知的兴趣点，防止推荐越来越窄。

- 强化学习：

YouTube:强化学习算法带来近两年最大的效果提升

- Top-K Off-Policy Correction for a REINFORCE Recommender System, WSDM 2019
- Reinforcement Learning for Slate-based Recommender Systems: A Tractable Decomposition and Practical Methodology, IJCAI 2019

谢谢观赏